

Trabalho Prático 01: Manipulação e Organização de Arquivos de Dados

Disciplina: Algoritmos e Estruturas de Dados II

Aluno: Thiago Ker Gama Nunes Carvalho

Matrícula: 23.2.8019

Roteiro de implementação e suas soluções:

1. Geração dos dados
2. Definição dos parâmetros de armazenamento
3. Simulação de escrita
4. Cálculo de estatísticas
5. Exibição dos resultados

1. Geração dos Dados

Para a criação dos registros, utilizei:

- **Biblioteca Faker:** responsável por gerar dados aleatórios baseados em informações reais do contexto brasileiro (nomes, CPFs etc.).
- **Dataclass:** utilizada para estruturar a classe Pessoa, aproximando-se da ideia de struct em C, permitindo um armazenamento organizado e tipado.
- **Biblioteca Random:** utilizada para sortear matrículas, anos de ingresso e coeficientes acadêmicos.

O código utiliza o encoding latin-1 e o locale pt_BR da biblioteca Faker para garantir compatibilidade na conversão de strings para bytes, evitando caracteres inválidos durante a escrita no arquivo binário.

A classe Pessoa concentra todos os campos necessários, e cada atributo já é formatado com limites adequados (ex.: nome com até 50 caracteres), garantindo que, ao gerar os registros, nenhum campo ultrapasse o espaço destinado a ele.

2. Entrada de Dados do Usuário

O programa solicita três informações principais:

- Quantidade de registros a serem gerados;
- Modo de armazenamento:
 - (1) Tamanho fixo,
 - (2) Tamanho variável (contíguo ou espalhado);
- Tamanho máximo de cada bloco em bytes.

Além disso, são definidos marcadores especiais:

0xFE: Para marcar o fim de um registro,

0xFF: Para indicar continuação quando um registro variável ultrapassa o limite de um bloco.

Que são utilizados para a organização interna dos dados no arquivo .dat.

3. Simulação de Escrita dos Registros

A primeira etapa da escrita consiste em gerar o cabeçalho do arquivo, contendo o tamanho do bloco e o modo de armazenamento, convertido diretamente para bytes.

- **Modo 1 - Registros de Tamanho Fixo**

Nesse modo, cada registro possui exatamente 169 bytes.

Portanto:

- O usuário deve escolher um tamanho de bloco no mínimo igual a 169 bytes
- Caso contrário, o programa encerra com erro

Os registros são montados concatenando todos os campos formatados.

Quando um registro tem espaço sobrando no bloco, esse espaço é preenchido com o caractere #, garantindo que todos os blocos permaneçam uniformes.

A alocação nos blocos é feita sequencialmente:

- Se o registro cabe no bloco atual, é adicionado
- Caso contrário, o bloco é fechado e um novo é iniciado

- **Modo 2 - Registros de Tamanho Variável**

Nesse modo, o registro é convertido para uma string única separada por vírgulas e finalizada com o marcador FE.

O usuário pode escolher:

- (1) Registros contíguos:
Todo o registro deve caber inteiramente dentro de um único bloco.
Caso ultrapasse o tamanho máximo, o programa informa o erro.
- (2) Registros espalhados:
O registro pode ser fragmentado entre vários blocos.
Quando o espaço do bloco acaba:
 - Grava-se o trecho possível;
 - Adiciona-se o marcador de continuação FF;
 - O restante vai para o próximo bloco.

Esse processo garante que o arquivo possa armazenar registros maiores do que o próprio bloco.

4. Cálculo das Estatísticas

Após concluir a escrita dos blocos no arquivo .dat, o programa inicia a etapa de análise e geração das estatísticas.

Os principais cálculos realizados são:

- **Total de blocos utilizados**

É simplesmente o número de blocos que foram preenchidos durante a etapa de armazenamento.

Esse valor indica o espaço efetivamente ocupado no arquivo, considerando o limite de bytes por bloco.

- **Cálculo dos bytes utilizados**

- **Modo Fixo:**

Como cada registro possui exatamente 169 bytes, os bytes úteis são obtidos diretamente pelo produto:
 $\text{quantidade_registros} \times 169$.

- **Modo Variável:**

O programa recalcula o tamanho real de cada registro (sem os marcadores), somando o tamanho de todos os campos codificados. Esse valor representa os *bytes verdadeiramente úteis*, desconsiderando fragmentação ou preenchimento.

- **Ocupação percentual dos blocos**

Para cada bloco, é calculado:

$$\text{Ocupação} = (\text{tamanho do bloco preenchido} / \text{tamanho máximo do bloco}) * 100$$

Essa métrica permite observar quão cheio cada bloco ficou e identificar possíveis perdas de espaço.

- **Percentual médio de ocupação**

É a média das ocupações individuais dos blocos, permitindo avaliar o nível geral de otimização do armazenamento.

- **Blocos parcialmente utilizados**

Conta quantos blocos não atingiram 100% da capacidade.

Esse dado é importante principalmente no modo de registros variáveis ou nos últimos blocos, indicando possíveis fragmentações ou sobras.

- **Eficiência de armazenamento**

A eficiência é calculada comparando:

$$\text{Eficiência} = (\text{bytes úteis} / \text{bytes totais disponíveis}) * 100$$

onde:

- Bytes úteis = tamanho real dos dados;
- Bytes totais disponíveis = número de blocos \times tamanho máximo do bloco.

Esse valor mostra quanto do espaço total foi efetivamente utilizado para armazenar informação relevante, desconsiderando fragmentação ou preenchimento.

5. Exibição dos Resultados

- Total de blocos utilizados
- Quantidade de blocos parcialmente ocupados
- Percentual médio de ocupação dos blocos
- Eficiência geral de armazenamento

Github: https://github.com/ThiagoKer/tp01_aeds2